



Regresión Lineal

Técnicas de AI: Regresiones, Deep Learning, otros

1. Introducción	3
2. Objetivos	4
2.1 Objetivo general	4
2.2 Objetivos específicos	4
3. Definición	5
3.1. Regresión lineal simple y regresión lineal múltiple	5
3.2. Tipología de la regresión lineal	6
4. Herramientas	7
Variable Aleatoria	7
Variable aleatoria discreta	7
Variable aleatoria continua	8
Esperanza Matemática	8
Varianza Matemática	10
Covarianza y correlación de pearson	12
Cálculo de coeficientes de la Regresión Lineal Simple	13
Cálculo muestral de coeficientes	16
Supuestos de la Regresión Lineal Simple	17
Test de Hipótesis	17
Contrastes de los supuestos	18
Regresión Lineal Múltiple	19
Intervalos de confianza en la regresión lineal	20
Métricas de evaluación del modelo de regresión lineal	21
Coeficiente de determinación	22

1. Introducción

Los métodos de predicción siempre han sido necesarios en el desarrollo de cualquier tipo de tarea o trabajo independientemente de su naturaleza o tipología. La predicción siempre viene acompañada de beneficio: si sé predecir con cierta garantía los resultados de un partido de fútbol podré apostar para conseguir beneficios, si puedo predecir el tipo de cliente que van a contratar servicios en mi empresa podré enfocar los productos para personalizarlos y maximizar los beneficios, etc.

A causa de esto, en base a los datos recogidos en cada uno de los campos de aplicación, se han desarrollado algoritmos matemáticos con la finalidad de predecir. Desde algoritmos básicos, compuestos por operaciones lineales, hasta algoritmos sofisticados compuestos por cálculos mucho más complicados.

Uno de los algoritmos más sencillos y a su vez más utilizados en la predicción (por su simpleza y su interpretabilidad) es la Regresión Lineal, que veremos en esta unidad didáctica. La Regresión Lineal es una técnica de predicción basada en una combinación lineal de valores a partir de unos coeficientes calculados siguiendo una determinada metodología. Como veremos durante la unidad, los ingredientes principales de la Regresión Lineal constan de una variable objetivo sobre la que realizaremos la predicción y unas variables predictoras que, multiplicadas por los parámetros calculados, servirán para calcular el valor de la predicción.

Desarrollaremos el tema atendiendo a los siguientes puntos principales:

- Comprensión del significado de Regresión Lineal así como de las herramientas estadísticas básicas para su desarrollo.
- Estudio del cálculo de coeficientes en una Regresión Lineal Simple y en una Regresión Lineal Múltiple
- Qué es un test de Hipótesis y cuáles son los supuestos que debe cumplir un modelo de Regresión Lineal
- Métricas de evaluación más relevantes en un modelo de Regresión Lineal

2. Objetivos

2.1 Objetivo general

- Comprender el funcionamiento de un modelo de Regresión Lineal y conocer las herramientas estadísticas para desarrollarlo, así como conocer la implementación de forma práctica en Python.

2.2 Objetivos específicos

- Entender las bases estadísticas teóricas sobre las que se sustenta un modelo de Regresión Lineal
- Saber distinguir entre Regresión Lineal Simple y Múltiple y conocer las técnicas de obtención de coeficientes
- Conocer la mecánica de un Test de Hipótesis y los supuestos que debe cumplir un modelo de Regresión Lineal
- Ser capaz de evaluar el rendimiento de un modelo de Regresión Lineal atendiendo a las diferentes métricas destinadas a ello
- Saber identificar la tipología de problemas donde sea factible el desarrollo de un modelo de Regresión Lineal
- Conocer la aplicación práctica de implementación de Regresión Lineal Simple y Múltiple de Python mediante la librería de scikit-learn y statsmodel

3. Definición

La Regresión Lineal es un método estadístico que se utiliza para modelar la relación entre una variable dependiente (o variable respuesta) y una o más variables independientes (variables predictoras).


La variable dependiente es el objetivo de la predicción y la o las variables predictoras son los valores que vamos a utilizar para calcular la predicción de la variable dependiente. El resultado de la aplicación del modelo de regresión lineal sobre una observación (de una o varias variables predictoras) es un valor predicho de la variable objetivo.

3.1. Regresión lineal simple y regresión lineal múltiple

Se dice que un modelo es una regresión lineal simple cuando únicamente utilizamos una variable predictora para calcular el valor de la variable objetivo. Por ejemplo cuando queremos calcular la velocidad máxima que puede alcanzar un coche atendiendo únicamente a su peso.

Un modelo es una regresión lineal múltiple cuando utilizamos varias variables predictoras para calcular el valor de la variable objetivo. Por ejemplo, cuando para calcular la velocidad máxima que puede alcanzar un coche utilizamos su peso, sus metros de longitud, sus caballos de potencia y su modelo de motor.

Dependiendo del tipo de regresión con el que estemos tratando nos podemos encontrar con dos fórmulas diferentes.



En estas fórmulas, la variable Y actúa como variable respuesta mientras que las variables X son las variables predictoras. Los coeficientes beta son los llamados coeficientes de la regresión y el

valor epsilon es el error de predicción del modelo. Todos los elementos que aparecen en ambas ecuaciones serán descritos durante la unidad didáctica con un mayor nivel de detalle.

3.2. Tipología de la regresión lineal

Según la técnica de modelado dentro del campo del aprendizaje automático, la regresión lineal se puede clasificar desde diversas perspectivas. En esta unidad didáctica estudiaremos la clasificación según la existencia o no de etiquetas en los datos, y según si el modelo es paramétrico o no paramétrico.

La regresión lineal es un tipo de **aprendizaje supervisado**, lo que significa que requiere un conjunto de datos etiquetado que incluye las características de entrada y los valores de la variable dependiente. Un modelo de regresión lineal se entrena utilizando estos datos para aprender la relación entre las variables dependientes y la variable objetivo. De esta forma, estableciendo una fórmula que parametrize dicha relación y dados unos valores observados de la variable dependiente, podremos predecir un valor de la variable objetivo.

Aunque la regresión lineal no es un algoritmo que se aplique en escenarios de **aprendizaje no supervisado**, es importante mencionar que este tipo de aprendizaje trabaja con datos no etiquetados. En los algoritmos de aprendizaje no supervisado, no se proporciona una variable objetivo para guiar el proceso de entrenamiento. En este enfoque, el modelo intenta encontrar patrones ocultos o estructuras inherentes en los datos. Ejemplos comunes de aprendizaje no supervisado son el clustering y la reducción de dimensionalidad. A diferencia de la regresión lineal, que requiere datos etiquetados para predecir una variable dependiente, los métodos no supervisados se centran en tareas como la segmentación de datos o la detección de anomalías.

Anteriormente hemos mencionado que la regresión lineal establece una fórmula que parametriza la relación entre la variable objetivo y las variables predictoras. La regresión lineal es un **modelo paramétrico**, lo que significa que asume una estructura funcional específica para la relación entre las variables (en este caso, una relación lineal) y se describe mediante un conjunto finito de parámetros (pendientes, intercepto, etc.). Este enfoque simplifica la interpretación y cálculo de las predicciones, pero también introduce una suposición importante: que los datos siguen esta estructura lineal subyacente. Si la relación entre las variables no es lineal, el rendimiento del modelo se puede ver limitado.

Aunque la regresión lineal es un modelo paramétrico, existen alternativas **no paramétricas** para modelar relaciones más complejas y no lineales entre las variables, como las técnicas basadas en árboles de decisión o métodos de vecinos más cercanos (k-NN). Estos modelos no asumen una forma específica de la función que relaciona las variables, lo que les permite adaptarse mejor a relaciones complejas, aunque a costa de ser más difíciles de interpretar y, a menudo, más costosos computacionalmente.

4. Herramientas

En el presente apartado describiremos las herramientas estadísticas fundamentales para la comprensión y el desarrollo de un modelo de regresión lineal. El único objetivo de la presentación de las fórmulas teóricas de las herramientas que trataremos, es la comprensión del origen de los cálculos estadísticos prácticos sobre poblaciones, en los que se basan los algoritmos de predicción.

Variable Aleatoria

Una variable aleatoria es una función que asigna un valor, usualmente numérico, al resultado de un experimento aleatorio. Un experimento aleatorio es la reproducción controlada de un fenómeno, existiendo incertidumbre sobre el resultado que se obtendrá, por ejemplo: tirar un dado. Existen dos tipos de variables aleatorias atendiendo al tipo de experimento aleatorio sobre el que se midan los resultados.

Variable aleatoria discreta

Una variable aleatoria discreta es aquella donde su dominio está definido dentro de un número finito de valores o infinito numerable. Esto quiere decir que podemos numerar los resultados que saldrán del experimento aleatorio que mida la variable. Por ejemplo la variable aleatoria definida como resultado de tirar un dado, cuyo dominio abarca los enteros desde 0 hasta 6 o la variable aleatoria definida como número de lanzamientos de una moneda necesarios hasta obtener una cruz, cuyo dominio abarca los enteros positivos.

$$P(X = x_i) = p_i$$

Su función de probabilidad está definida por la siguiente ecuación:

La ecuación ha de interpretarse como “probabilidad de que la variable aleatoria X tome el valor x_i es igual a p_i ”.

En el primer ejemplo, atendiendo a un dado perfecto la probabilidad de cada resultado (desde 1 hasta 6) sería $\frac{1}{6}$. En el segundo caso la función de probabilidad es un poco más compleja (suponemos siempre una moneda perfecta, con la misma probabilidad de salir cara que de salir cruz):

- La probabilidad de que la variable aleatoria sea 1, o sea, de que se necesite un lanzamiento para obtener una cruz es 0.5, puesto que hay las mismas posibilidades en un único lanzamiento de que salga cara que de que salga cruz.

- La probabilidad de que la variable aleatoria sea 2, o sea, de que se necesiten dos lanzamientos para obtener una cruz es 0.5^2 , puesto que necesitamos que salga cara en el primer lanzamiento (probabilidad 0.5) y además que salga cruz en el segundo lanzamiento (probabilidad 0.5).
- Siguiendo este segundo caso podemos llegar al caso general N. La probabilidad de que se necesiten N lanzamientos para obtener una cruz es 0.5^N puesto que necesitamos N-1 caras en los N-1 lanzamientos (probabilidad $0.5^{(N-1)}$) y una cruz en el lanzamiento N (probabilidad 0.5). Entonces, $0.5^{(N-1)} \cdot 0.5 = 0.5^N$

La función de distribución se define como la función que mide la probabilidad de que la variable aleatoria tome valores menores o iguales a uno dado, es decir:

$$F(x) = \sum_{x_i \leq x} P(x_i)$$

Variable aleatoria continua

Una variable aleatoria continua es aquella donde su dominio es un intervalo de la recta real, una unión de varios intervalos, o la totalidad de la recta real. Por ejemplo la variable aleatoria definida como resultado de medir la temperatura en un lugar determinado o la variable aleatoria definida como resultado del tiempo de espera de una cola.

En el primer caso el dominio es la totalidad de la recta real y en el segundo caso es los números positivos de la recta real.

La función de densidad de una variable aleatoria continua se define como la función que describe la distribución de dicha variable. La integral de la función de densidad entre dos puntos de la recta real A, B, resulta la probabilidad de que la variable aleatoria tome un valor

$$P(A \leq X \leq B) = \int_A^B f_X(x) dx$$

entre dichos puntos:

La función de distribución en este caso se define de la misma forma que en el caso discreto,

$$F(x) = \int_{-\infty}^x f_X(u) du$$

pero esta vez aplicada sobre la función de densidad:

Esperanza Matemática

La esperanza de una variable aleatoria X, es el concepto que formaliza la idea de valor medio de un fenómeno aleatorio. Describe el promedio ponderado de todos los valores posibles que una variable aleatoria puede tomar, considerando sus probabilidades.

La definición de esperanza matemática varía ligeramente dependiendo de si se trata de una variable aleatoria discreta o de una variable aleatoria continua.

Para variables aleatorias discretas se describe de la siguiente manera:

$$\mathbb{E}(X) = \sum_i x_i P(x_i)$$

Es decir, la suma de todos los valores posibles que puede tomar la variable aleatoria multiplicados por su probabilidad.

En el caso del dado la esperanza matemática de la variable aleatoria asociada a este experimento se calcula como: $\frac{1}{6} * 1 + \frac{1}{6} * 2 + \dots + \frac{1}{6} * 6 = \frac{1}{6} * (1+2+3+4+5+6) = \frac{1}{6} * 21 = 3,5$. Esto quiere decir que cuantas más veces tiramos el dado, más cercano va a estar la suma de valores entre el número de intentos de 3,5.

Para variables aleatorias continuas se describe como sigue:

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x) dx$$

Podemos captar la idea de esperanza continua si pensamos en una variable aleatoria continua como una discreta con infinitos puntos x_i . Para calcular la esperanza necesitaríamos un sumatorio infinito de $x_i * P_i$. Sustituyendo el sumatorio por la integral y la función de probabilidad por la de densidad obtenemos la expresión buscada. En el módulo no se entrará al detalle de definir de manera matemática el caso continuo.

La esperanza matemática es un operador lineal, esto quiere decir que

$$\begin{aligned} \mathbb{E}[X + Y] &= \mathbb{E}[X] + \mathbb{E}[Y] \\ \mathbb{E}[cX] &= c \mathbb{E}[X] \end{aligned}$$

En notación matemática utilizamos la letra μ para referirnos a $\mathbb{E}(X)$

Cuando hablamos de población que sigue una determinada distribución, el concepto de esperanza se traduce en Media Poblacional. Si extraemos una muestra de dicha población hablamos de Media Muestral o Empírica.

- Media poblacional: Se denota por μ y su expresión es $\frac{1}{n} \sum_{\forall i \in P} X_i$ donde P es la población y $\#(P) = n$

- Media muestral: Se denota por $\bar{x}$ y su expresión es $\frac{1}{m} \sum_{\forall i \in M \subset P} X_i$ donde M es una muestra de tamaño $\#(M) = m$

Varianza Matemática

La varianza es una medida de dispersión que se utiliza para representar la variabilidad de un conjunto de datos respecto de la media aritmética de los mismos. La varianza de una variable aleatoria se define como la esperanza del cuadrado de la desviación de dicha variable respecto

a su media, esto es: $Var(X) = E[(X - \mu)^2]$

Cuanto más alejados estén los resultados de un experimento aleatorio, de la esperanza de la variable aleatoria definida como resultado de dicho experimento, mayor será la varianza de la variable aleatoria.

Por ejemplo si definimos dos variables aleatorias diferentes de la siguiente forma:

- Variable aleatoria 1: Número de asistentes a los eventos organizados por una determinada gestora.
- Variable aleatoria 2: Temperatura medida de forma diaria en un pueblo de Siberia.

Supongamos que esa gestora organiza eventos de diferente tipología, como festivales, congresos o fiestas populares. La varianza de la variable aleatoria 1 será presumiblemente alta pues en algunos de esos eventos como fiestas populares tendrán una afluencia mucho menor que grandes festivales. En cambio, la temperatura de un pueblo de Siberia anualmente va a ser mucho menos variante, pues siempre rondará temperaturas similares (muy bajo cero).

Dependiendo si la variable aleatoria con la que tratamos es continua o es discreta, la Varianza se calculará de una forma o de otra. A continuación exponemos el cálculo en el caso continuo y el cálculo en el caso discreto:

- Variable aleatoria discreta:
$$Var(X) = \sum_i (x_i - \mu)^2 P(x_i)$$
- Variable aleatoria continua:
$$Var(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x) dx$$

La aplicación de la fórmula general en los casos continuo y discreto es trivial a partir de la definición de esperanza matemática.

La varianza matemática tiene las siguientes propiedades:

- La varianza de una variable aleatoria siempre es mayor o igual a cero.

- La varianza de una constante siempre es cero.

$$Var(aX) = a^2 Var(X)$$

-
- $Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$ Donde "Cov" se traduce como covarianza y veremos su definición en la siguiente sección.

Traduciendo la definición teórica en aplicación práctica, suponiendo que tenemos una población P con $\#(P)=n$, y extraemos de dicha población una muestra M con $\#(M)=m$.

Podemos definir la varianza poblacional y muestral de la siguiente manera:

- Varianza poblacional: Se define como el sumatorio de la diferencia entre cada una de las observaciones de la población y la media poblacional al cuadrado, dividido entre el

$$\sigma^2 = \sum_{\forall i \in P} \frac{(x_i - \mu)^2}{n}$$

número de observaciones de la población.

- Varianza muestral: Se define como el sumatorio de la diferencia entre cada una de las observaciones de la muestra y la media muestral al cuadrado, dividido entre el número

$$s^2 = \sum_{\forall i \in M \subset P} \frac{(x_i - \bar{x})^2}{m-1}$$

de observaciones de la muestra menos 1.

En los materiales del campus virtual podréis acceder a la explicación del factor m-1 de la varianza muestral.

Covarianza y correlación de pearson

La covarianza es un valor que indica el grado de variación conjunta de dos variables aleatorias

respecto a sus medias, esto es:

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])]$$

Dicho de una manera más sencilla, la covarianza es una forma de medir si dos distribuciones de variables aleatorias tienden a aumentar o disminuir al mismo tiempo. La idea que podemos obtener de la fórmula propuesta es la siguiente:

- La covarianza es la esperanza de la variable aleatoria producto: $(X-E[X]) \cdot (Y-E[Y])$. Por lo tanto, valores más altos de dicho producto se traducirán en covarianzas más altas. Y para que los valores de dicho producto sean altos tiene que coincidir que X esté alejado de su media cuando Y lo está.

Traduciendo la definición de covarianza a términos poblacionales obtenemos los siguientes cálculos:

- La covarianza poblacional se define como el sumatorio del producto de las observaciones de la primera población menos su media poblacional por las observaciones de la segunda población menos su media poblacional divididas entre el número de observaciones de la población. Esto es,

$$\sigma_{XY} = \sum_{\forall i \in P} \frac{(x_i - \mu_X)(y_i - \mu_Y)}{n}$$

- La covarianza muestral se define como el sumatorio del producto de las observaciones de la primera muestra menos su media muestral, por las observaciones de la segunda muestra menos su media muestral dividido entre el tamaño de la muestra menos uno.

$$s_{XY} = \sum_{\forall i \in M \subset P} \frac{(x_i - \bar{X})(y_i - \bar{Y})}{m-1}$$

Esto es,

Hay un inconveniente a la hora de medir la variación conjunta de dos variables mediante la covarianza y es que ésta depende de las unidades de medida de las variables. Por ello se antoja necesario una métrica estandarizada que no dependa de las unidades de medida.

El coeficiente de correlación de Pearson es una medida de dependencia lineal entre dos variables aleatorias cuantitativas. A diferencia de la covarianza, la correlación de Pearson es independiente de la escala de medida de las variables.

Su fórmula general teórica viene dada por la siguiente expresión:

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}$$

Traduciendo la fórmula general a una muestra de variables aleatorias, obtenemos la siguiente

expresión:

$$r_{XY} = \frac{\sum_i (x_i - \bar{X})(y_i - \bar{Y})}{\sqrt{\sum_i (x_i - \bar{X})^2 \sum_i (y_i - \bar{Y})^2}}$$

Cálculo de coeficientes de la Regresión Lineal Simple

La regresión lineal busca predecir los valores de una variable aleatoria Y (denominada variable objetivo) a partir de otra variable aleatoria X (denominada variable predictora), mediante una combinación lineal. En primera instancia, representamos el modelo de regresión lineal simple como $Y = \beta_0 + \beta_1 X$ donde los coeficientes β determinarán el valor predicho de la variable Y.

Es decir, voy a utilizar unos coeficientes fijos β tales que dado un valor de mi variable aleatoria X, multiplicando y sumando con estos coeficientes, voy a tener una predicción de la variable aleatoria Y. La predicción no va a ser exacta, así que debemos asumir un error que denotamos por ϵ . El error ϵ será una nueva variable aleatoria que se define como “resultado de restar el valor real de la variable aleatoria Y a la predicción de Y dada por $\beta_0 + \beta_1 X$ “. Por lo tanto, el

modelo queda totalmente definido por la expresión siguiente:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

A partir de esa definición lo que necesitamos es encontrar los parámetros β que minimicen el error ϵ . Es decir, de todos los parámetros posibles, queremos aquellos que hagan que las predicciones sean lo más parecidas al valor real. Traducido a lenguaje matemático, buscamos en primera instancia: $\min_{\beta_0, \beta_1} Y - (\beta_0 + \beta_1 X)$.

No podemos calcular un mínimo dependiente de variables aleatorias, pues nuestro resultado estaría sujeto a incertidumbre. En lugar de eso, debemos utilizar alguna herramienta que sirva para eliminar la incertidumbre, en este caso la esperanza matemática, mediante la cual podemos obtener un resultado determinístico. De esta forma, nuestra expresión del mínimo quedaría: $\min_{\beta_0, \beta_1} E[Y - (\beta_0 + \beta_1 X)]$.

Ahora bien, al intentar minimizar esta expresión notamos que la diferencia puede ser tanto positiva como negativa, lo que puede llevar a cancelaciones que no reflejen la magnitud de los errores. Es por eso que utilizamos el cuadrado de la diferencias, lo que asegura que todas las desviaciones se consideren positivamente y evita la cancelación de errores positivos y negativos: $\min_{\beta_0, \beta_1} E[(Y - (\beta_0 + \beta_1 X))^2]$.

Derivaremos e igualaremos a cero la expresión para encontrar los coeficientes β que mejor predicen nuestra variable Y en el modelo de regresión lineal. Al método de búsqueda de coeficientes mediante esta técnica se le denomina Método de Mínimos Cuadrados.

Tenemos entonces la siguiente función que vamos a derivar con respecto a cada coeficiente para hallar el valor mínimo: $MSE = \mathbb{E}[(Y - (\beta_0 + \beta_1 X))^2]$

Tomamos ahora la derivada con respecto a β_0 e igualamos a cero: (Para realizar esta derivada asumimos que podemos intercambiar derivada y esperanza, que en este caso es cierto, la demostración excede el material de la unidad)

$$\begin{aligned} \partial_{\beta_0} MSE = 0 &\longrightarrow \partial_{\beta_0} MSE = \mathbb{E}[-2(Y - \beta_0 - \beta_1 X)] = 0 \longrightarrow \mathbb{E}[Y - \beta_0 - \beta_1 X] = 0 \longrightarrow \\ &\longrightarrow \mathbb{E}[Y] = \beta_0 + \beta_1 \mathbb{E}[X]^{(1)} \end{aligned}$$

Lo hacemos de igual forma para β_1 :

$$\begin{aligned} \partial_{\beta_1} MSE = 0 &\longrightarrow \partial_{\beta_1} MSE = \mathbb{E}[-2X(Y - \beta_0 - \beta_1 X)] = 0 \longrightarrow \mathbb{E}[XY - \beta_0 X - \beta_1 X^2] = 0 \longrightarrow \\ &\longrightarrow \mathbb{E}[XY] - \beta_0 \mathbb{E}[X] - \beta_1 \mathbb{E}[X^2] = 0 \longrightarrow \mathbb{E}[XY] = \beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X^2]^{(2)} \end{aligned}$$

Tomando las expresiones (1) y (2) obtenemos el sistema:

$$\begin{cases} \beta_0 + \beta_1 \mathbb{E}[X] = \mathbb{E}[Y] \\ \mathbb{E}[XY] = \beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X^2] \end{cases}$$

Si multiplicamos la primera expresión por $\mathbb{E}[X]$ y sumamos ambas expresiones obtenemos:

$$\begin{aligned} \beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X]^2 + \mathbb{E}[XY] &= \mathbb{E}[Y] \mathbb{E}[X] + \beta_0 \mathbb{E}[X] + \beta_1 \mathbb{E}[X^2] \longrightarrow \\ &\longrightarrow \mathbb{E}[Y] \mathbb{E}[X] - \mathbb{E}[XY] = \beta_1 (\mathbb{E}[X]^2 - \mathbb{E}[X^2]) \end{aligned}$$

$$Cov(X, Y) = \beta_1 Var(X) \longrightarrow \beta_1 = \frac{Cov(X, Y)}{Var(X)}$$

Por lo tanto:

El coeficiente β_1 de nuestro modelo de regresión lineal $Y = \beta_0 + \beta_1 X$ indicará la pendiente de la recta de regresión. En este momento debemos imponer que $Var(X)$ sea desigual a cero, de lo contrario el coeficiente β_1 no será calculable. Más adelante comentaremos el sentido gráfico de esta imposición.

Despejando de la primera ecuación: $\beta_0 = \mathbb{E}[Y] - \beta_1 \mathbb{E}[X]$

De la expresión anterior obtenemos que:

$$E(Y) - \beta_0 - \beta_1 E(X) = 0 \rightarrow E(Y - \beta_0 - \beta_1 X) = 0 \rightarrow E(\epsilon) = 0$$

Además, tenemos que:

$$E(Y) - \beta_0 - \beta_1 E(X) = 0 \rightarrow E(Y - \beta_0 - \beta_1 X) = 0 \rightarrow E(\epsilon) = 0$$

Y por otro lado:

$$Cov(X, \epsilon) = Cov(X, Y - \beta_0 - \beta_1 X) = E[(X - E(X))(Y - \beta_0 - \beta_1 X - E(Y - \beta_0 - \beta_1 X))]$$

Como la $E[Y - \beta_0 - \beta_1 X] = E[\epsilon] = 0$ tenemos:

$$E[(X - E(X))(Y - \beta_0 - \beta_1 X)] = E[X(Y - \beta_0 - \beta_1 X)] - E[E(X)(Y - \beta_0 - \beta_1 X)]$$

Sabemos que $E[X(Y - \beta_0 - \beta_1 X)] = 0$ por la expresión deducida en (2).


$$\text{Además: } E[E(X)(Y - \beta_0 - \beta_1 X)] = E[X]E[Y - \beta_0 - \beta_1 X] = E[X]E[\epsilon] = 0$$

Por lo tanto: $Cov(X, \epsilon) = 0$

De los coeficientes calculados por el método de mínimos cuadrados deducimos entonces que $E(\epsilon) = 0$ (la esperanza de la variable aleatoria error es 0) y $Cov(X, \epsilon) = 0$ (la covarianza entre la variable predictora y la variable aleatoria error es 0, no hay relación entre X y ϵ). Entonces, ¿para cualesquiera variables aleatorias X e Y cumpliendo $Var(X)=0$ puedo realizar una regresión lineal simple y atender a las métricas de calidad del modelo para verificar su validez? La respuesta es que no.

Es cierto que para cualesquiera variables aleatorias X e Y cumpliendo $Var(X)=0$ puedes llevar a cabo el cálculo de la regresión lineal por mínimos cuadrados y cumplirá $E(\epsilon) = 0$ y $Cov(X, \epsilon) = 0$. Incluso puede ser que las métricas de calidad del modelo sean satisfactorias. Pero un modelo de regresión lineal debe de cumplir unos supuestos antes de asumir su validez.

La siguiente imagen grafica lo que estamos comentando. Corresponde al Cuarteto de Ascombe y son cuatro regresiones lineales cuyas métricas y valores estadísticos son similares, pero no todas cumplen los supuestos de regresión lineal. Por este motivo es tan importante asegurarse de que un modelo cumple los supuestos antes de darlo por válido.



Cálculo muestral de coeficientes

Antes de enunciar los supuestos de la regresión lineal, vamos a traducir toda la teoría vista en cuanto a cálculo de coeficientes a la práctica. En lugar de tener dos variables aleatorias X e Y que representan teóricamente la distribución de una población, ahora tenemos una muestra de valores $x_1, \dots, x_N$ e $y_1, \dots, y_N$. Nuestro modelo teóricamente queda definido por

$$Y = \beta_0 + \beta_1 X + \epsilon$$

Traduciendo esta expresión a la práctica, tendremos $y_i = \beta_0 + \beta_1 x_i + \epsilon_i \forall i \in \{1, \dots, N\}$.

Sabemos que $\beta_1 = \frac{Cov(X,Y)}{Var(X)}$, por lo tanto aplicando las fórmulas muestrales vistas en las herramientas iniciales obtendremos el cálculo del valor del coeficiente dada la muestra:

$$\beta_1 = \frac{\sum_i \frac{(x_i - \bar{x})(y_i - \bar{y})}{N-1}}{\sum_i \frac{(x_i - \bar{x})^2}{N-1}} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

Por otro lado tenemos que $\beta_0 = E(Y) - \beta_1 E(X)$

Aplicando la fórmula muestral y sustituyendo por el valor de β_1 :

$$\beta_0 = \bar{y} - \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \bar{x}$$

Supuestos de la Regresión Lineal Simple

Como decimos, antes de confirmar la validez de un modelo, debemos atender a que cumple ciertas condiciones. En el caso de que efectivamente cumpla estos supuestos podemos asumir que es un modelo útil para nuestro propósito (en mayor o menor medida atendiendo a las métricas de calidad). Los supuestos son los siguientes.

- Linealidad: La relación entre la variable independiente y dependiente debe ser lineal en el rango de valores observados.
- Homocedasticidad: Los residuos deben distribuirse de forma homogénea para todos los valores de la variable de predicción.
- Normalidad: Los residuos deben seguir una distribución normal.
- Independencia: Los residuos son independientes entre sí.

Ahora, ¿cómo hago para verificar los supuestos dada la muestra de valores $x_1, \dots, x_N$ e $y_1, \dots, y_N$. Haremos uso de los Test de Hipótesis que detallamos a continuación.

Test de Hipótesis

Un test de hipótesis es un procedimiento para juzgar si una propiedad que se supone en una población estadística es compatible con lo observado en una muestra de dicha población.

Se denomina hipótesis nula (denotada por H_0) a la hipótesis que se desea contrastar. Por otra parte la hipótesis alternativa (denotada por H_1) es la hipótesis contraria, que utilizaremos para el contraste.

La metodología de un contraste de hipótesis es la siguiente: a partir de mi muestra (obtenida de una variable aleatoria) se extrae un estadístico (esto es, un valor que es función de la muestra) cuya distribución de probabilidad sea conocida.

Tomamos como región de rechazo al conjunto de valores más improbable bajo la hipótesis, esto es, el conjunto de valores para el que rechazaremos la hipótesis nula si el valor del estadístico observado entra dentro de él. La región de rechazo depende de un nivel de significancia α prefijado.

Denominamos p-valor a la probabilidad de que el estadístico calculado sea posible dada la hipótesis nula cierta. Comparando este p-valor con el nivel de significancia, podremos aceptar la hipótesis nula o rechazarla en favor de la hipótesis alternativa.

Al comparar los resultados del test con los datos observados, se presenta esta tabla que ilustra los errores tipo 1 y tipo 2:

	H_0 Acepto	H_0 Rechazo
H_0 Verdadera		Tipo I, α
H_0 Falsa	Tipo II, β	

Contrastes de los supuestos

El supuesto de linealidad se puede contrastar mediante el siguiente test de hipótesis llamado Test Reset de Ramsey:

- H_0 El modelo se explica de forma correcta con valores lineales
- H_1 Hay que recurrir a valores no lineales para predecir la variable

El supuesto de homocedasticidad se puede contrastar mediante el siguiente test de hipótesis denominado Test de Breusch-Pagan

- H_0 Los residuos son homocedásticos
- H_1 Los residuos no son homocedásticos

El supuesto de normalidad se puede contrastar mediante el siguiente test de hipótesis denominado Test de Shapiro-Wilk

- H_0 La distribución de los valores estudiados es normal
- H_1 La distribución de los valores estudiados no es normal

El supuesto de independencia de residuos se puede contrastar mediante el siguiente test de Hipótesis denominado Test de Durbin-Watson

H_0 Existe autocorrelación entre los residuos

H_1 No existe autocorrelación entre los residuos

Regresión Lineal Múltiple

Partimos de nuestro modelo de regresión lineal simple $Y = \beta_0 + \beta_1 X + \epsilon$. Como definimos al inicio de la unidad, un modelo es una regresión lineal múltiple cuando utilizamos varias variables predictoras para calcular el valor de la variable objetivo. Nuestro modelo queda

definido como: $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1} + \epsilon$

Si utilizamos subíndices para referirnos a las observaciones y superíndices para referirnos a las variables podemos obtener la siguiente matriz muestral generalizada:

$$\begin{bmatrix} 1 & 1 & \dots & 1 \\ X_1^1 & X_2^1 & \dots & X_n^1 \\ \vdots & \vdots & \ddots & \vdots \\ X_1^{p-1} & X_2^{p-1} & \dots & X_n^{p-1} \end{bmatrix}$$

Atendiendo a que nuestra variable Y será un vector con tantas componentes como observaciones tengamos, podemos representar nuestro modelo de forma matricial como

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

mostramos a continuación:

Al igual que con la regresión lineal simple, buscamos minimizar los errores para todas las

observaciones, esto es, minimizar el vector β para la expresión: $\sum_{obs} (Y_i - X_i^T \beta)^2$

Utilizando formato de norma euclídea la expresión (mínimos cuadrados para la regresión lineal

múltiple) se puede reescribir como $\|\mathbf{Y} - \mathbf{X}\beta\|^2$

Entonces podemos escribir nuestro problema de minimización como $\min_{t \in \mathbb{R}^p} \|\mathbf{Y} - \mathbf{X}t\|^2$

Si trabajamos la expresión a minimizar obtenemos lo siguiente:

$$\|Y - Xt\|^2 = \|Y\|^2 + \|X\|^2 - 2X^T Y t = \|Y\|^2 + t^T X^T X t - 2X^T Y t$$

Derivando con respecto a t e igualando a 0 obtenemos:

$$\partial_t(\|Y\|^2 + t^T X^T X t - 2X^T Y t) = 2X^T X t - 2X^T Y = 0$$

Buscamos entonces la solución $\hat{\beta}$ que verifique: $2X^T X \hat{\beta} = 2X^T Y$

Para obtener dicha solución necesitamos imponer que $X^T X$ sea invertible, y de esta forma:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Intervalos de confianza en la regresión lineal

Denominamos ahora β al vector de parámetros de la población parametrizada por las variables aleatorias X e Y . Queremos saber la distribución de los parámetros $\hat{\beta}$ calculados al obtener diferentes muestras observadas de las poblaciones parametrizadas por X e Y .

Nuestro modelo poblacional lo expresamos como $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1} + \epsilon$
(matricialmente $Y = X\beta + \epsilon$).

Supongamos que se cumplen los supuestos de la regresión lineal. Entonces tenemos que $\epsilon \sim N(0, \sigma^2)$, osea los residuos se distribuyen mediante una normal con media 0 y varianza constante σ^2 . De esta afirmación, aplicando el teorema de transformación lineal para la distribución normal multivariante $Y \sim N(X\beta, \sigma^2)$. Y como $\hat{\beta} = (X^T X)^{-1} X^T Y$, aplicando el mismo teorema que en el paso anterior obtenemos que:

$$\hat{\beta} \sim \mathcal{N}((X^T X)^{-1} X^T X \beta, \sigma^2 (X^T X)^{-1} X^T I_p ((X^T X)^{-1} X^T)^T)$$

Simplificando: $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (X^T X)^{-1})$

Queremos calcular un intervalo de confianza para nuestro parámetro $\hat{\beta}$ calculado por el método de mínimos cuadrados.

Como desconocemos la varianza σ^2 de la distribución normal del parámetro, el intervalo de confianza ha de calcularse sobre una distribución t de Student con n-p grados de libertad (donde n es el número de observaciones y p es el número de variables predictoras).

$$\begin{aligned} \hat{\beta}_0 \pm t_{df}^{\alpha/2} SE(\hat{\beta}_0) \\ \hat{\beta}_1 \pm t_{df}^{\alpha/2} SE(\hat{\beta}_1) \end{aligned}$$

Obtenemos así el intervalo de confianza

donde

$$SE(\hat{\beta}_0) = \sqrt{\frac{s^2}{n} \left(1 + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)}$$

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

y

$$s = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2}}$$

Métricas de evaluación del modelo de regresión lineal

Una vez que se ha ajustado un modelo es necesario verificar su eficiencia, ya que aun siendo la línea que mejor se ajusta a las observaciones de entre todas las posibles y cumpliendo los supuestos de la regresión lineal, el modelo puede ser ineficiente.

Las métricas de evaluación del modelo con las que contamos son las siguientes:

- **Error medio absoluto (MAE)** es la media del valor absoluto de los errores. Es la medida más fácil de entender, ya que es sólo el error promedio.
- **Error cuadrático medio (MSE)** es la media de los errores al cuadrado.
- **Raíz cuadrada del error cuadrático medio (RMSE)** es la raíz cuadrada de la anterior medida.
- **Error absoluto relativo (RAE)**, también conocido como la suma residual de cuadrado.
- **Error cuadrático relativo (RSE)** es muy similar a «Error absoluto relativo», pero se usa para calcular R-cuadrado. R-cuadrado no es un error, si no, una métrica popular para la precisión de su modelo.

Describimos a continuación su expresión matemática:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\epsilon_i|$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\epsilon_i)^2$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\epsilon_i)^2}$$

$$\text{RAE} = \frac{\sum_{i=1}^n |\epsilon_i|}{\sum_{i=1}^n |Y_i - \bar{Y}|}$$

$$\text{RSE} = \sqrt{\frac{\sum_{i=1}^n (\epsilon_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

$$\text{Donde } \epsilon_i = Y_i - \hat{Y}_i$$

Coeficiente de determinación

El coeficiente de determinación describe la proporción de variabilidad observada en la variable dependiente Y explicada por el modelo y relativa a la variabilidad total.

En los modelos de regresión lineal simple el valor de R^2 se corresponde con el cuadrado del coeficiente de correlación de Pearson (r) entre X e Y, no siendo así en regresión múltiple.

Existe una modificación de R^2 conocida como R^2 -ajustado que se emplea principalmente en los modelos de regresión múltiple. Introduce una penalización cuantos más predictores se incorporan al modelo. En los modelos lineales simples no se emplea.

$$R^2 = \frac{\text{Suma de cuadrados totales} - \text{Suma de cuadrados residuales}}{\text{Suma de cuadrados totales}} =$$

$$1 - \frac{\text{Suma de cuadrados residuales}}{\text{Suma de cuadrados totales}} =$$

$$1 - \frac{\sum (\hat{y}_i - y_i)^2}{\sum (y_i - \bar{y})^2}$$

Bibliografía

Harrell, F. (2016). Regression modeling strategies: With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis. Springer.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to Linear Regression Analysis. John Wiley & Sons.

Weisberg, S. (2013). Applied Linear Regression. John Wiley & Sons.

Faraway, J. J. (2016). Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models. Chapman & Hall/CRC Texts in Statistical Science.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: with Applications in R. Springer.

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow: Concepts, Tools, and Techniques to Build Intelligent Systems.

Anexo: Recursos

Práctica 1 Regresión Lineal



Práctica: Herramientas de la regresión lineal

Dadas un par de muestras de tamaño 150 sobre una población:

- 1) Determina la media y varianza muestral para cada una de las muestras
- 2) Determina la covarianza de la muestra y la correlación de Pearson
- 3) Atendiendo a la correlación de Pearson: ¿qué podemos afirmar sobre la relación entre las muestras?

Práctica 2 Regresión Lineal



Práctica: Cálculo de coeficientes para la regresión lineal

Dada una muestra de tamaño 150 de observaciones de las variables X e Y:

- 1) Dibujar e interpretar el gráfico de dispersión entre las dos variables, ¿tendría sentido aplicar regresión lineal?
- 2) Calcular manualmente los coeficientes β del problema de regresión de Y sobre X
- 3) Comparar los coeficientes obtenidos con los datos por la librería scikit-learn

Práctica 3 Regresión Lineal



Práctica: Aplicación práctica de regresión lineal

Dada una BBDD asociada a información sociodemográfica de los habitantes de 50 ciudades:

- 1) Aplicar un método de división previo al entrenamiento del modelo
- 2) Entrenar el modelo con el conjunto escogido
- 3) Comprobar que se cumplen los supuestos de la regresión lineal
- 4) Calcular el Error Medio Absoluto, el Error Cuadrático Medio y el coeficiente de determinación

WELCOME
— TO —
UAX

UAX

Universidad
Alfonso X el Sabio

GRACIAS

UAX.COM